

# Modelado e identificación de sistemas respiratorios: Comparación entre sujetos sano y patológico mediante técnicas paramétricas.

Omar Santiago Acevedo Londoño, Juan Esteban Pineda Lopera, Sofia Raigosa Buriticá

**Resumen:** Este artículo presenta la identificación de un modelo dinámico del sistema respiratorio humano a partir de señales de flujo y volumen obtenidas de dos sujetos: uno sano y otro con una condición de distensibilidad pulmonar aumentada. Las señales fueron preprocesadas mediante un filtro FIR para eliminar ruido de alta frecuencia, y se evaluaron cuatro estructuras clásicas de modelado (BJ, ARMAX, ARX y OE). El modelo OE presentó el mejor desempeño en términos de error cuadrático medio e índice de ajuste, siendo seleccionado para un análisis de sensibilidad que identificó los parámetros más influyentes. Estos se optimizaron para adaptar el modelo al sujeto patológico, logrando una respuesta simulada coherente con la señal real. Finalmente, el análisis temporal y frecuencial reveló diferencias fisiológicas claras entre los sujetos. Los resultados muestran que un modelo determinista ajustado a señales filtradas permite representar eficazmente la dinámica respiratoria, con potencial aplicación en simulación fisiológica y análisis clínico.

## I. INTRODUCCIÓN

La mecánica respiratoria humana puede modelarse como un sistema dinámico cuya respuesta está determinada por parámetros fisiológicos clave, como la resistencia de las vías aéreas, la distensibilidad pulmonar (compliance) y la inercia de los tejidos [1]. Estos parámetros influyen directamente en señales medibles como el flujo de aire y el volumen pulmonar, permitiendo inferir el estado funcional del sistema respiratorio [1]. Alteraciones en estas propiedades reflejan tanto variaciones fisiológicas como condiciones patológicas, siendo por tanto fundamentales para el análisis clínico y la simulación fisiológica [2].

En el ámbito de la bioingeniería, el modelado matemático de estos sistemas permite una representación cuantitativa de la función respiratoria, facilitando la comprensión de su comportamiento bajo diferentes condiciones [2]. Específicamente, las técnicas de identificación de sistemas permiten estimar modelos dinámicos a partir de datos experimentales, relacionando entradas (por ejemplo, flujo respiratorio) con salidas (volumen pulmonar) mediante estructuras como ARX, OE, ARMAX, entre otras [3].

Este artículo presenta el proceso de identificación estructural de la dinámica respiratoria a partir de señales obtenidas de dos sujetos: uno sano y otro con una patología asociada al aumento de la distensibilidad pulmonar. Se emplearon técnicas paramétricas para ajustar modelos que describen la relación entre flujo y volumen, evaluando su desempeño mediante datos de validación. Posteriormente, se realizó un análisis de sensibilidad para seleccionar los parámetros más influyentes, optimizándolos para adaptar el modelo al sujeto patológico. Finalmente, se compararon los comportamientos dinámicos en el dominio temporal y frecuencial, interpretando los resultados en términos fisiológicos.

## II. METODOLOGÍA

### II-A Visualización de datos.

El análisis inició con la exploración visual de las señales de flujo (entrada) y volumen (salida) correspondientes a tres conjuntos de datos: sujeto 1 (sano), validación y sujeto 2 (con condición patológica). Cada conjunto incluía señales de flujo, volumen y su vector de tiempo asociado. Las señales fueron analizadas en el dominio temporal para evaluar su morfología y comportamiento dinámico, mientras que en el dominio frecuencial se aplicó la transformada rápida de Fourier (FFT) para identificar componentes espectrales dominantes y caracterizar el contenido de ruido. Estas visualizaciones permitieron evidenciar diferencias en la forma y contenido espectral de las señales entre los sujetos y entre los diferentes conjuntos.

### II-B Preprocesado.

A partir del análisis espectral, se determinó que las señales presentaban componentes de alta frecuencia no fisiológicas, presumiblemente asociadas a ruido instrumental o interferencias no relacionadas con la dinámica respiratoria. Para mitigar estos efectos, se diseñó un filtro digital de tipo FIR (Finite Impulse Response) de fase lineal, pasa bajas, el cual permite preservar la forma temporal de las señales sin introducir distorsiones en la fase [4]. El filtro se diseñó utilizando una ventana de Hann, cuya relación entre el ancho

de la banda de transición  $\Delta F$  y el orden  $N$  del filtro está dada por:

$$\Delta F = \frac{3.1}{\text{Orden}} \quad (1)$$

La frecuencia respiratoria normal para adultos sin patologías oscila entre 18 - 22 rpm (0.3 - 0.37 Hz), pudiendo alcanzar hasta 30 rpm (0.5 Hz) en casos de taquipnea severa [5]. Este rango fisiológico justificó la selección de una frecuencia de corte de 1 Hz (60 rpm) para el filtrado, valor que duplica el umbral superior patológico mientras preserva las componentes esenciales del sistema respiratorio.

$$\Delta F = \frac{1}{1000} \quad (2)$$

$$\frac{3.1}{\text{Orden}} = \frac{1}{1000} \quad (3)$$

$$\text{Orden} = 3100 \quad (4)$$

Este orden elevado garantiza una alta capacidad de atenuación en la banda de rechazo, llegando a reducir hasta 100 veces (40 dB) las componentes no deseadas [4]. La respuesta del filtro fue evaluada gráficamente en términos de magnitud adimensional, magnitud en decibelios y fase.

El filtrado fue implementado mediante el método `filtfilt`, que aplica el filtro en ambas direcciones temporales, asegurando una respuesta con fase cero [4]. Este proceso se aplicó tanto a las señales de entrada como de salida de los tres conjuntos de datos (sujeto 1, validación y sujeto 2). La efectividad del filtrado fue verificada mediante comparaciones visuales entre las señales originales (con ruido) y las señales procesadas.

### II-C Identificación del sistema.

Con las señales del sujeto 1 ya filtradas, se procedió a la identificación de un modelo dinámico que describiera la relación entre el flujo de aire (entrada) y el volumen pulmonar (salida). Para ello, se implementaron cuatro estructuras clásicas de identificación paramétrica: Box-Jenkins (BJ), ARMAX, ARX y Output Error (OE). Estas estructuras representan distintas aproximaciones al modelado de la dinámica determinista del sistema y del comportamiento del ruido [3].

Sin embargo, en la implementación práctica, los modelos fueron estimados y simulados considerando únicamente la parte determinista, debido a que la simulación del ruido del sistema no era directa ni fiable con los datos disponibles. Esta decisión se justificó por el hecho de que las señales fueron previamente filtradas para eliminar el componente de ruido, el cual no era trivial de caracterizar ni reproducir en las simulaciones. Por tanto, el enfoque se centró en modelar la dinámica del sistema a partir de las señales preprocesadas  $u_1(n)$  y  $y_1(n)$ , y validar los modelos con los datos independientes de validación  $u_v(n)$  y  $y_v(n)$ , correspondientes al mismo sujeto. A continuación, se describen las ecuaciones generales en el dominio Z de cada estructura, los órdenes seleccionados y los procedimientos implementados.

#### - Box – Jenkins (BJ)

El modelo Box-Jenkins es el más general de los utilizados y permite separar explícitamente las dinámicas del sistema y del ruido. Se define por [3]:

$$y(n) = \frac{B(z)}{F(z)} u(n - n_k) + \frac{C(z)}{D(z)} e(n) \quad (5)$$

Donde:

$$B(z) = b_1 z^{-1} + \dots + b_{n_b} z^{-n_b} \quad (6)$$

$$F(z) = 1 + f_1 z^{-1} + \dots + f_{n_f} z^{-n_f} \quad (7)$$

$$C(z) = 1 + c_1 z^{-1} + \dots + c_{n_c} z^{-n_c} \quad (8)$$

$$D(z) = 1 + d_1 z^{-1} + \dots + d_{n_d} z^{-n_d} \quad (9)$$

En este caso se seleccionaron los órdenes:  $n_b = 1$ ,  $n_f = 1$ ,  $n_c = 1$ ,  $n_d = 1$  y  $n_k = 1$ . El modelo se estimó mediante la función `bj`, y su salida fue simulada como la suma de la respuesta determinista (bloque  $B(z)/F(z)$ ) y la respuesta al ruido estimado (bloque  $C(z)/D(z)$ ).

#### - Autoregresivo con media móvil y entrada exógena (ARMAX)

El modelo ARMAX amplía la estructura ARX incorporando un modelo autorregresivo para el ruido. La ecuación en el dominio Z es [3]:

$$y(n) = \frac{B(z)}{A(z)}u(n) + \frac{C(z)}{A(z)}e(n) \quad (10)$$

Donde:

$$A(z) = 1 + a_1z^{-1} + \dots + a_{n_a}z^{-n_a} \quad (11)$$

$$B(z) = b_1z^{-1} + \dots + b_{n_b}z^{-n_b} \quad (12)$$

$$C(z) = 1 + c_1z^{-1} + \dots + c_{n_c}z^{-n_c} \quad (13)$$

Se emplearon los órdenes  $n_a = 2$ ,  $n_b = 2$ ,  $n_c = 1$  y un retraso  $n_k = 1$ . Este modelo permite capturar dinámicas tanto deterministas como estocásticas. Se ajustó mediante la función `armax`, y su salida se simuló como la suma de dos componentes: la salida determinista al estímulo de entrada filtrado y la salida estocástica inducida por el ruido estimado.

#### - Autoregresivo con entrada exógena (ARX)

El modelo ARX describe la salida como una combinación lineal de valores pasados de la salida y la entrada, más un término de error blanco. Su representación en el dominio Z es [3]:

$$y(n) = \frac{B(z)}{A(z)}u(n) + \frac{1}{A(z)}e(n) \quad (14)$$

Donde:

$$A(z) = 1 + a_1z^{-1} + \dots + a_{n_a}z^{-n_a} \quad (15)$$

$$B(z) = b_1z^{-1} + \dots + b_{n_b}z^{-n_b} \quad (16)$$

Para este modelo se seleccionaron los órdenes:  $n_a = 3$ ,  $n_b = 1$  y un retraso  $n_k = 1$ . El modelo fue estimado mediante la función `armx`.

#### - Output error (OE)

La estructura OE modela únicamente la parte determinista del sistema, asumiendo que el ruido afecta directamente la salida y no se retroalimenta. Su forma en el dominio Z es [3]:

$$y(n) = \frac{B(z)}{F(z)}u(n) + e(n) \quad (17)$$

Donde:

$$B(z) = b_1z^{-1} + \dots + b_{n_b}z^{-n_b} \quad (18)$$

$$F(z) = 1 + f_1z^{-1} + \dots + f_{n_f}z^{-n_f} \quad (19)$$

Para este modelo se usaron los órdenes  $n_b = 1$ ,  $n_f = 3$  y  $n_k = 1$ . El modelo se ajustó utilizando la función `oe`, y la simulación de su respuesta se realizó únicamente con la señal de entrada filtrada, sin considerar explícitamente el modelado del ruido.

### II-D Comparación de modelos.

Para comparar el desempeño de los modelos identificados, se utilizaron dos métricas cuantitativas: la raíz del error cuadrático medio (RMSE) [6] y el índice de ajuste (fit score), calculadas tanto sobre el conjunto de entrenamiento como sobre el de validación.

#### - Error cuadrático medio (RMSE)

$$RMSE = \sqrt{\frac{1}{N} \sum_{n=1}^N (y_{real}(n) - y_{modelo}(n))^2} \quad (20)$$

#### - Índice de ajuste (Fit score)

$$FIT = 100 \times \left( 1 - \frac{\|y_{real} - y_{modelo}\|}{\|y_{real} - \bar{y}_{real}\|} \right) \quad (21)$$

Donde  $\|\cdot\|$  representa la norma Euclídea y  $\bar{y}_{real}$  es el valor medio de la señal real. Estas métricas se calcularon tanto para el conjunto de identificación como para el conjunto de validación, permitiendo comparar el desempeño de los modelos en términos de precisión y capacidad de generalización.

Estas métricas permitieron evaluar la precisión y la fidelidad con que cada modelo replicaba la señal real. Además, se realizaron comparaciones visuales entre la señal de salida real y la estimada por cada modelo, facilitando una evaluación cualitativa de su desempeño.

## II-E Análisis de sensibilidad.

Una vez identificado el modelo que describe la dinámica respiratoria del sujeto 1, se realizó un análisis de sensibilidad paramétrica con el objetivo de determinar cuáles de los coeficientes del modelo influyen de manera más significativa en la salida del sistema. Esta etapa es fundamental para reducir la complejidad del modelo sin comprometer su capacidad de representación, lo que además permite realizar una optimización más eficiente sobre un subconjunto de parámetros clave [7].

El modelo utilizado en esta etapa fue representado en forma de función de transferencia continua con numerador y denominador definidos por los coeficientes identificados previamente:

$$G(s) = \frac{As + B}{Cs^3 + Ds^2 + Es + F} \quad (22)$$

Donde los parámetros corresponden a:

- Numerador:  $A = b_2, B = b_3$
- Denominador:  $C = a_1, D = a_2, E = a_3, F = a_4$

La simulación del sistema ante la entrada filtrada  $u_1(t)$  se realizó con la función `lsim`, y se evaluó la salida  $y_{pred}(t)$  frente a la señal real  $y_1(t)$  del sujeto 1.

Para estimar la sensibilidad de cada parámetro, se aplicaron perturbaciones porcentuales desde -50% hasta +50% respecto a su valor de referencia, con pasos de 5%. En cada caso, se evaluó el error cuadrático total entre la salida simulada y la real, definido como [8]:

$$J = \sum_{n=1}^N \left( y_{pred}(n) - y_1(n) \right)^2 \quad (23)$$

Este procedimiento se repitió para cada uno de los seis parámetros, generando una matriz  $J$  de errores cuadráticos para cada combinación de parámetro y perturbación. Posteriormente, se normalizó cada columna de la matriz  $J$  con respecto a su valor máximo, con el fin de comparar las curvas de sensibilidad relativa entre parámetros de distinta escala.

Los resultados se visualizaron en un gráfico que muestra la variación del error normalizado en función del cambio porcentual de cada parámetro. Las curvas resultantes

permiten identificar los parámetros más sensibles como aquellos cuya alteración produce un mayor incremento en el error. Este criterio será utilizado en la siguiente etapa para seleccionar un subconjunto reducido de parámetros a optimizar para el sujeto 2.

## II-F Optimización.

A partir del análisis de sensibilidad, se identificaron los cuatro parámetros más influyentes sobre la salida del sistema respiratorio modelado:  $b_2, b_3, a_3$  y  $a_4$ . Estos parámetros fueron seleccionados como variables de ajuste para adaptar el modelo inicialmente entrenado con los datos del sujeto 1 a los datos del sujeto 2, que presenta una condición fisiopatológica distinta, caracterizada por un aumento en la distensibilidad pulmonar.

La optimización se formuló como un problema de minimización del error cuadrático acumulado entre la salida simulada del modelo y la señal real del sujeto 2. Para ello, se definió una función de costo  $J$  de la forma:

$$J(\theta) = \sum_{n=1}^N |y_2(n) - \hat{y}_2(n; \theta)| \quad (24)$$

Donde  $y_2(n)$  es la salida real del sujeto 2,  $\hat{y}_2(n; \theta)$  es la salida predicha por el modelo para una combinación dada de parámetros y  $\theta = [b_2, b_3, a_3, a_4]$  representa el subconjunto de parámetros ajustables. El modelo se mantuvo con estructura fija en sus componentes menos sensibles, conservando los valores de  $a_1 = 1$  y  $a_2 = -2.99$ , previamente identificados como poco sensibles. La función de costo fue evaluada mediante simulación en tiempo discreto con la función `dlsim`, utilizando como entrada la señal  $u_2$  filtrada.

Para resolver el problema de optimización, se utilizó el algoritmo Nelder-Mead, un método basado en simplex que no requiere el cálculo del gradiente, siendo apropiado para problemas no lineales y con posibles irregularidades locales [9]. Como condición inicial se usaron los valores originales de los parámetros obtenidos para el sujeto 1.

El proceso de optimización se ejecutó con un límite de 500 iteraciones, y una vez alcanzada la convergencia, se obtuvo el conjunto óptimo de parámetros para el sujeto 2. La respuesta del sistema ajustado fue comparada con la señal real del sujeto, evidenciando la calidad del ajuste mediante superposición gráfica de ambas señales.

## II-G Análisis en tiempo y frecuencia.

Con el fin de caracterizar dinámicamente los modelos obtenidos para los dos sujetos, se realizó un análisis tanto en el dominio temporal como en el frecuencial. Este análisis permite comprender la respuesta del sistema respiratorio ante una entrada impulsiva y su comportamiento frente a diferentes frecuencias, aspectos relevantes en la interpretación fisiológica de los parámetros obtenidos.

Primero, se implementó la función `dimpulse` para calcular la respuesta al impulso de los modelos identificados. Esta operación se realizó sobre los sistemas en notación discreta definidos por sus coeficientes del numerador y denominador, es decir:

$$H(z) = \frac{b_2 z^{-2} + b_3 z^{-3}}{1 + a_2 z^{-1} + a_3 z^{-2} + a_4 z^{-3}} \quad (25)$$

Esta función permite observar cómo responde el sistema ante un estímulo elemental, lo cual es útil para estudiar la estabilidad, rapidez de respuesta y el efecto de las características fisiológicas sobre el sistema modelado. Se graficaron las respuestas al impulso para los dos sujetos, lo que permitió comparar su comportamiento dinámico en el tiempo.

Posteriormente, se analizó el comportamiento en el dominio de la frecuencia utilizando la función `freqz`, que calcula la respuesta en frecuencia del sistema discreto. A partir de esta, se generaron diagramas de Bode que incluyen tanto la magnitud (expresada en decibelios) como la fase (en grados) frente a la frecuencia digital normalizada. Este análisis permite identificar el tipo de filtro implementado por el sistema respiratorio (por ejemplo, atenuación de altas frecuencias) y cómo las propiedades mecánicas (como la distensibilidad pulmonar aumentada en el sujeto patológico) afectan la respuesta del sistema frente a distintos rangos de frecuencia.

## III. RESULTADOS

### III-A Visualización de datos.

En la Figura 1 se presentan las señales originales de flujo (entrada) y volumen (salida) correspondientes a los tres grupos de datos, evaluadas en el dominio temporal. Se

observa una relación no lineal entre la entrada y la salida de las señales, así como un desfase temporal aparente.

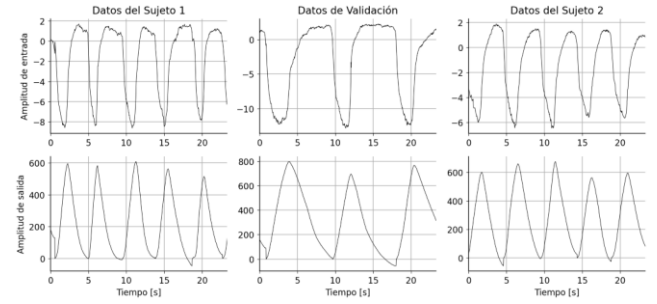


Figura 1. Representación gráfica de los datos crudos en el dominio temporal.

En la Figura 2 se muestra el espectro de potencia de las señales de entrada y salida para los mismos conjuntos de datos. Se evidencia en las salidas la presencia de componentes de alta frecuencia en todas las señales, indicando presencia de ruido, lo cual motiva la etapa de preprocesado.

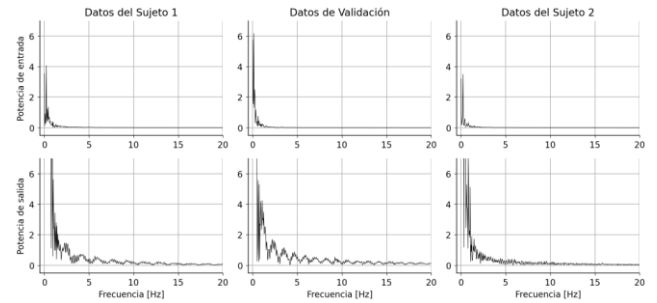


Figura 2. Espectro de potencia de las señales originales.

### III-B Preprocesado

En la Figura 3 se representa la respuesta del filtro FIR diseñado. Se incluyen las curvas de magnitud (adimensional), magnitud en decibelios y fase, evidenciando un comportamiento de filtro pasa bajas con fase lineal.




Figura 3. Respuesta del filtro FIR.

La Figura 4 presenta la comparación entre las señales originales y las señales filtradas de los tres conjuntos de datos. La atenuación de las componentes de alta frecuencia es evidente, conservando la forma general de la señal.

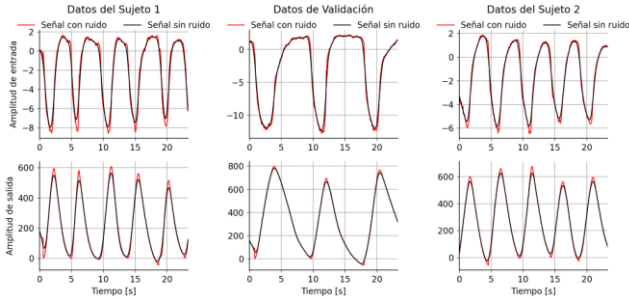


Figura 4. Gráfico comparativo entre las señales originales y filtradas en el dominio del tiempo.

### III-C Identificación del sistema.

Se ajustaron cuatro estructuras de modelos a partir de las señales preprocesadas del sujeto 1. A continuación, se listan los coeficientes estimados para cada uno:

#### - Modelo BJ

B: [0, 11.4976, -11.6068]

C: [1, -0.0101]

D: [1, -0.9999]

F: [1, -0.9987]

#### - Modelo ARMAX

A: [1, -1.9967, 0.9967]

B: [0, 9.1309, -18.3715, 9.2405]

C: [1, -0.9959]

#### - Modelo ARX

A: [1, -2.9989, 2.9979, -0.9989]

B: [0, -0.000112, 0.000116]

#### - Modelo OE

B: [0, -0.0001198, 0.0001194]

F: [1, -2.9989, 2.9979, -0.9989]

### III-D Comparación de modelos.

Las métricas cuantitativas de desempeño se calcularon para los conjuntos de identificación y validación, incluyendo el RMSE y el índice de ajuste (fit). Los resultados se presentan en la Tabla 1.

Modelo	RMSE (Identificación)	FIT (Identificación)	RMSE (Validación)	FIT (Validación)
OE	66.66	55.26%	114.83	49.76%
ARX	$1.78 \times 10^9$	$-1.21 \times 10^9\%$	$6.45 \times 10^8$	$-3.51 \times 10^8\%$
ARMA	9620.23	-6441.56%	6358.89	-2962.91%
X				
BJ	7281.50	-4964.78%	7284.81	-3462.86%

Tabla 1. Métricas de desempeño de los modelos (Identificación y validación)

La Figura 5 muestra la comparación entre las señales reales y las predichas por cada modelo sobre el conjunto de identificación. Por su parte, la Figura 6 muestra la misma comparación para el conjunto de validación.

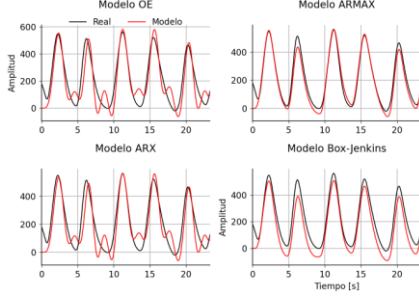


Figura 5. Comparación de salidas reales vs predichas por los modelos (identificación).




Figura 6. Comparación de salidas reales vs predichas por los modelos (validación).

El modelo que presentó mejor desempeño fue el OE, cuya ecuación en el dominio Z es:

$$y(z) = \frac{b_2 z^{-1} + b_3 z^{-2}}{1 + a_2 z^{-1} + a_3 z^{-2} + a_4 z^{-3}} u(z-1) + e(n) \quad (26)$$

Donde:

$$\begin{aligned} b_2 &= -0.00011198 \\ b_3 &= 0.00011155 \\ a_2 &= -2.99893166 \\ a_3 &= 2.99787201 \\ a_4 &= -0.99894034 \end{aligned}$$

### III-E Análisis de sensibilidad

La Figura 7 representa los resultados del análisis de sensibilidad paramétrica. Se observa la variación del error cuadrático normalizado para perturbaciones de  $\pm 50\%$  aplicadas individualmente sobre cada parámetro del modelo.




Figura 7. Sensibilidad del error frente a la variación de cada parámetro del modelo OE.

### III-F Optimización

A partir del análisis anterior, se seleccionaron los parámetros más influyentes para su optimización:  $b_2$ ,  $b_3$ ,  $a_3$ ,  $a_4$ . Tras 500 iteraciones del algoritmo Nelder-Mead, se obtuvo el siguiente conjunto óptimo de parámetros adaptado al sujeto 2:

$$\begin{aligned} b_2 &= -0.0001124 \\ b_3 &= 0.0001117 \\ a_1 &= 1 \text{ (fijo)} \\ a_2 &= -2.9989 \text{ (fijo)} \\ a_3 &= 2.9979 \\ a_4 &= -0.9989 \end{aligned}$$

La Figura 8 muestra la superposición entre la salida simulada del modelo optimizado y la señal real del sujeto 2.




Figura 8. Comparación entre la salida del modelo optimizado y la señal real del sujeto 2.

### III-G Análisis en tiempo y frecuencia

Las respuestas al impulso en el dominio temporal observadas en la figura 9 mostraron que el sistema del sujeto 1 presenta una respuesta más rápida y con menor amplitud en comparación con el sistema del sujeto 2, cuya respuesta es más prolongada y de mayor magnitud. La gráfica del sistema 1 evidencia una caída rápida en la salida tras el estímulo inicial, indicando un sistema más estable y con menor retardo

en la respuesta. En contraste, el sistema 2 muestra una respuesta más prolongada y de mayor amplitud, sugiriendo una mayor persistencia del efecto del estímulo.




Figura 9. Respuesta al impulso en el dominio temporal del sistema del sujeto 1 y 2.

En el análisis en frecuencia (figura 10), las gráficas del diagrama de Bode revelan que ambos sistemas presentan una atenuación en altas frecuencias, pero el sistema del sujeto 2 mantiene una mayor magnitud en el rango de frecuencias medias y altas, lo que indica una mayor capacidad de respuesta a frecuencias elevadas comparado con el sistema del sujeto 1. La fase también muestra diferencias significativas: en el sistema 2, la fase aumenta linealmente con la frecuencia, mientras que en el sistema 1 se observa una respuesta más estable y con menor desplazamiento de fase, reflejando distintas propiedades dinámicas y mecánicas entre los dos sujetos.

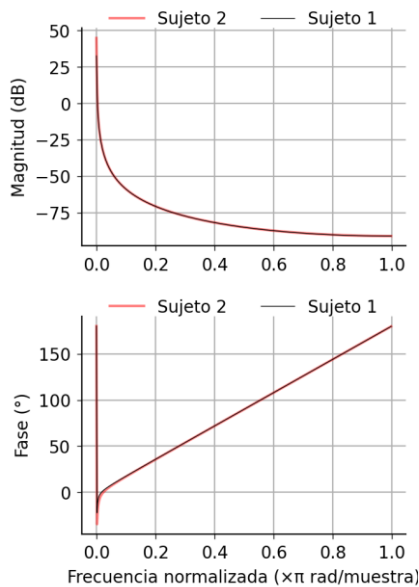


Figura 10. Respuesta en frecuencia: Magnitud y Fase en el diagrama de Bode, para los sujetos 1 y 2.

## IV. DISCUSIÓN

Los resultados obtenidos a lo largo del estudio permiten establecer conclusiones relevantes en torno a la dinámica entre el flujo respiratorio y el volumen pulmonar, así como sobre la eficacia de los métodos utilizados en el modelado y ajuste del sistema.

En la etapa de visualización de datos, las señales mostraron características que anticipaban la necesidad de un preprocesamiento adecuado. Las discrepancias temporales entre picos de entrada y salida evidenciaron la presencia de retardo, y el análisis en frecuencia reveló un espectro con múltiples componentes no asociadas a la fisiología esperada. Este comportamiento sugiere la presencia de ruido aditivo que puede comprometer la fidelidad de los modelos si no se filtra apropiadamente. Así, la implementación de un filtro FIR de fase lineal fue justificada y necesaria para preservar la morfología de la señal mientras se reducía el contenido no fisiológico.

La aplicación del filtro permitió eliminar componentes de alta frecuencia sin afectar la forma de las señales, lo cual se reflejó visualmente en la comparación entre datos originales y filtrados. Esta mejora en la calidad de las señales facilitó el proceso de identificación, asegurando que los modelos paramétricos se ajustaran a una señal más representativa de la dinámica real del sistema.

En cuanto a la identificación, se implementaron cuatro estructuras clásicas. Los modelos ARMAX, ARX y BJ, no lograron un buen desempeño, lo que sugiere que el comportamiento del ruido residual no es fácilmente representable mediante términos autoregresivos ni de media móvil. Por el contrario, el modelo OE, que omite el modelado del ruido y se centra exclusivamente en la dinámica determinista, presentó resultados significativamente superiores tanto en términos de RMSE como de índice de ajuste, en los conjuntos de identificación y validación. Esto indica que, para el caso particular de las señales respiratorias filtradas, una aproximación determinista pura resulta más adecuada.

La ecuación obtenida para el modelo OE mostró coeficientes con magnitudes pequeñas en el numerador, lo cual es esperable considerando la relación de escala entre flujo y volumen, mientras que los coeficientes del denominador reflejan una dinámica autoregresiva de tercer orden. Esta



estructura permitió capturar el comportamiento temporal del sistema con precisión aceptable.

El análisis de sensibilidad aportó información adicional sobre la relevancia relativa de cada parámetro del modelo OE. Se observó que las mayores variaciones en el error ocurren cuando se perturban los coeficientes  $b_2$ ,  $b_3$ ,  $a_3$  y  $a_4$  lo que sugiere que estos parámetros concentran la mayor parte de la capacidad de ajuste del modelo. Esta información permitió reducir el espacio de búsqueda durante la etapa de optimización.

Finalmente, la optimización sobre el sujeto 2, que presentaba una condición fisiopatológica distinta, logró adaptar eficazmente el modelo previamente identificado. El algoritmo Nelder-Mead ajustó los parámetros más sensibles, alcanzando una salida simulada que se aproximó a la señal real con buena correspondencia visual. Este resultado confirma que la estructura del modelo OE es flexible y que puede ser adaptada a diferentes condiciones fisiológicas mediante ajustes selectivos sobre un subconjunto de parámetros clave.

El análisis en el dominio temporal revela que el sistema respiratorio del sujeto 1 responde de manera rápida y con menor persistencia ante un estímulo impulsivo, lo cual puede estar relacionado con una mayor elasticidad pulmonar o menor resistencia en sus vías respiratorias, característicos de una fisiología más saludable. En cambio, el sistema del sujeto 2 presenta una respuesta más prolongada y de mayor magnitud, lo que puede indicar alteraciones en la mecánica respiratoria, como una menor distensibilidad pulmonar o mayor resistencia, características típicas en condiciones patológicas.

## V. CONCLUSIONES

El presente estudio demostró la viabilidad y utilidad del modelado dinámico del sistema respiratorio mediante técnicas de identificación de sistemas aplicadas a señales de flujo y volumen. A partir de datos experimentales de sujetos con distintas condiciones fisiológicas, fue posible ajustar modelos paramétricos que representan adecuadamente la relación entre las variables respiratorias.

El preprocesamiento de las señales mediante filtrado FIR fue esencial para eliminar componentes de ruido no fisiológicas, permitiendo una identificación más robusta y precisa de los modelos. Este paso resultó determinante, especialmente

considerando que el ruido residual no fue modelado explícitamente en las simulaciones por su complejidad y baja reproducibilidad, lo que justificó el uso de modelos centrados exclusivamente en la dinámica determinista.

Entre las estructuras evaluadas (BJ, ARMAX, ARX y OE), el modelo Output Error (OE) evidenció el mejor desempeño, con métricas cuantitativas superiores y una respuesta simulada más cercana a la señal real. Este resultado sugiere que, para señales adecuadamente preprocesadas, una representación determinista sin modelado explícito del ruido puede ser más efectiva que estructuras complejas con componentes estocásticas.

El análisis de sensibilidad permitió identificar los parámetros más influyentes en la salida del modelo, lo cual no solo aporta conocimiento sobre la estructura interna del sistema, sino que también facilita la reducción de la complejidad computacional durante etapas posteriores de ajuste o personalización del modelo.

Finalmente, el proceso de optimización aplicado al sujeto con condición patológica permitió adaptar de manera efectiva el modelo original, demostrando que es posible capturar diferencias fisiológicas significativas a través de cambios controlados en un subconjunto de parámetros. Los análisis temporales y frecuenciales confirmaron que estas diferencias están asociadas a variaciones en las propiedades mecánicas del sistema respiratorio, como la distensibilidad y la respuesta ante frecuencias elevadas.

En conjunto, los resultados validan el uso de modelos deterministas ajustados con datos filtrados como una herramienta eficaz para el análisis de la mecánica respiratoria y su eventual aplicación en entornos clínicos o simulaciones fisiológicas personalizadas.

## REFERENCIAS

- [1] A. R. Carvalho y W. A. Zin, "Respiratory system dynamical mechanical properties: modeling in time and frequency domain," *Biophysical Reviews*, vol. 3, no. 1, pp. 71–84, 2011. DOI: 10.1007/s12551-011-0048-5.
- [2] J. H. T. Bates y G. B. Allen, "The Estimation of Lung Mechanics Parameters in the Presence of Pathology: A Theoretical Analysis," *Annals of Biomedical Engineering*, vol. 34, no. 3, pp. 384–392, Mar. 2006. DOI: 10.1007/s10439-005-9056-6.

[3] N. Akshaykumar y D. Subbulekshmi, "Process Identification with Autoregressive Linear Regression Method using Experimental Data: Review," *Indian Journal of Science and Technology*, vol. 9, no. 39, Oct. 2016, doi: 10.17485/ijst/2016/v9i39/91470.

[4] H. M. Tun, "Photoplethysmography (PPG) Scheming System Based on Finite Impulse Response (FIR) Filter Design in Biomedical Applications," *International Journal of Electrical and Electronic Engineering & Telecommunications*, vol. 10, no. 4, pp. 272–282, Jul. 2021, doi: 10.18178/ijeetc.10.4.272-282.

[5] McGee S. Respiratory rate and abnormal breathing patterns. In: McGee S, ed. Evidence-Based Physical Diagnosis. 5th ed. Philadelphia, PA: Elsevier; 2022:chap 19.

[6] T. Chai and R. R. Draxler, "Root mean square error (RMSE) or mean absolute error (MAE)?," *Geosci. Model Dev. Discuss.*, vol. 7, pp. 1525–1534, 2014, doi: 10.5194/gmdd-7-1525-2014.

[7] T. Russi, A. Packard, R. Feeley, and M. Frenklach, "Sensitivity Analysis of Uncertainty in Model Prediction," *J. Phys. Chem. A*, vol. 112, no. 12, pp. 2579–2588, 2008, doi: 10.1021/jp076861c.

[8] S. A. Billings and K. L. Lee, "Nonlinear Fisher discriminant analysis using a minimum squared error cost function and the orthogonal least squares algorithm," *Neural Networks*, vol. 15, no. 2, pp. 263–270, Mar. 2002, doi: 10.1016/S0893-6080(02)00014-2.

[9] M. A. Luersen y R. Le Riche, "Globalized Nelder–Mead method for engineering optimization," *Computers and Structures*, vol. 82, no. 23-24, pp. 2251–2260, 2004, doi: 10.1016/j.compstruc.2004.03.072.