

MODELADO E IDENTIFICACIÓN DE SISTEMAS RESPIRATORIOS MEDIANTE TÉCNICAS PARAMÉTRICAS.



Omar Santiago Acevedo Londoño, Juan Esteban Pineda Lopera, Sofía Raigosa Buriticá
Programa de Bioingeniería, Universidad de Antioquia, Medellín.

1 INTRODUCCIÓN

Se identificó un modelo dinámico del sistema respiratorio humano a partir de señales de flujo y volumen de un sujeto sano y otro con distensibilidad pulmonar aumentada. Utilizando técnicas de identificación de sistemas, se evaluaron cuatro estructuras clásicas (BJ, ARMAX, ARX y OE), destacando el modelo OE por su mejor desempeño. Las señales fueron filtradas con un FIR y se aplicó un análisis de sensibilidad para optimizar los parámetros más influyentes, logrando una simulación coherente con la fisiología del sujeto patológico. El análisis temporal y frecuencial reveló diferencias fisiológicas claras. El estudio demuestra que un modelo determinista ajustado a datos experimentales permite representar eficazmente la dinámica respiratoria, con aplicaciones potenciales en análisis clínico y simulación fisiológica.

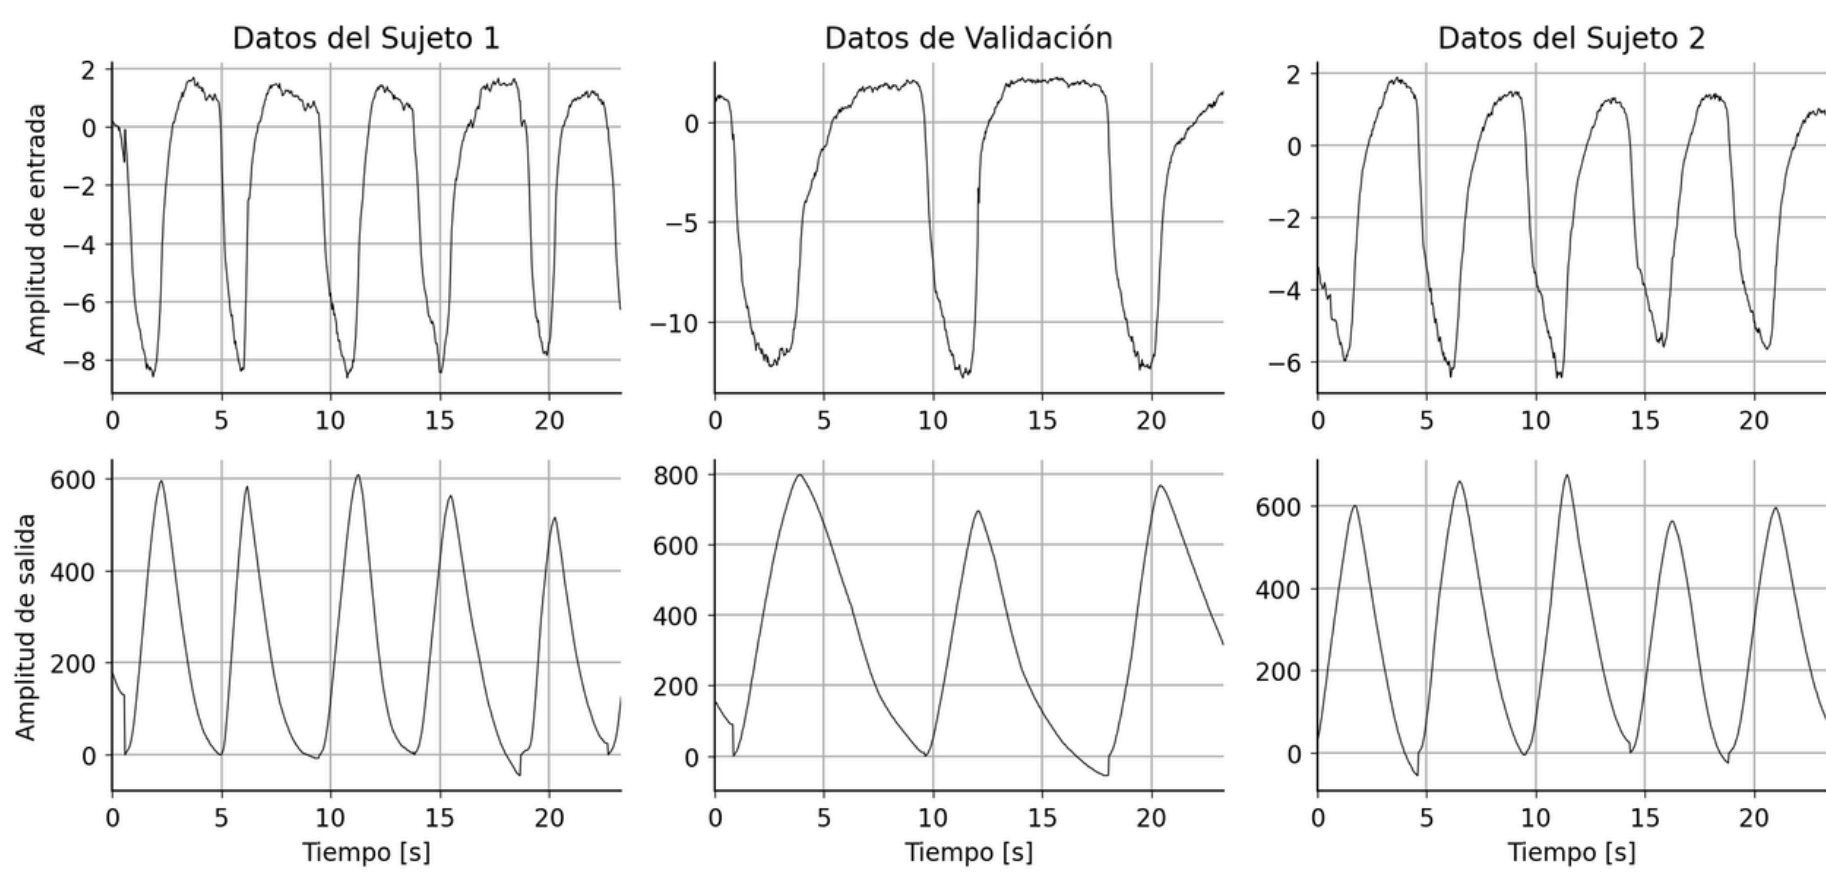


FIGURA 1: VISUALIZACIÓN SEÑALES

2 OBJETIVOS

1. Modelar la dinámica del sistema respiratorio humano como un sistema dinámico basado en parámetros fisiológicos clave (resistencia, distensibilidad e inercia).
2. Identificar y ajustar modelos matemáticos a partir de señales de flujo y volumen obtenidas de dos sujetos (uno sano y otro con distensibilidad pulmonar aumentada), utilizando técnicas de identificación de sistemas.
3. Analizar e interpretar diferencias fisiológicas entre los sujetos mediante comparaciones en el dominio temporal y frecuencial.
4. Demostrar la aplicabilidad del modelo ajustado para representar con precisión la dinámica respiratoria, con potencial uso en simulación fisiológica y análisis clínico.

3 METODOLOGÍA

1. Visualización y Preprocesamiento de Datos

Se realizó una exploración visual de las señales en los dominios temporal y frecuencial para identificar su morfología, comportamiento y contenido de ruido. Se observaron componentes de alta frecuencia no fisiológicas, lo que justificó la implementación de un **filtro FIR** de fase lineal pasa bajas con una **frecuencia de corte de 1 Hz**. Este filtro, diseñado con una ventana de **Hann** y un **orden de 3100**, se aplicó bidireccionalmente usando el método *filtfilt* para eliminar el ruido sin distorsionar la fase de las señales.

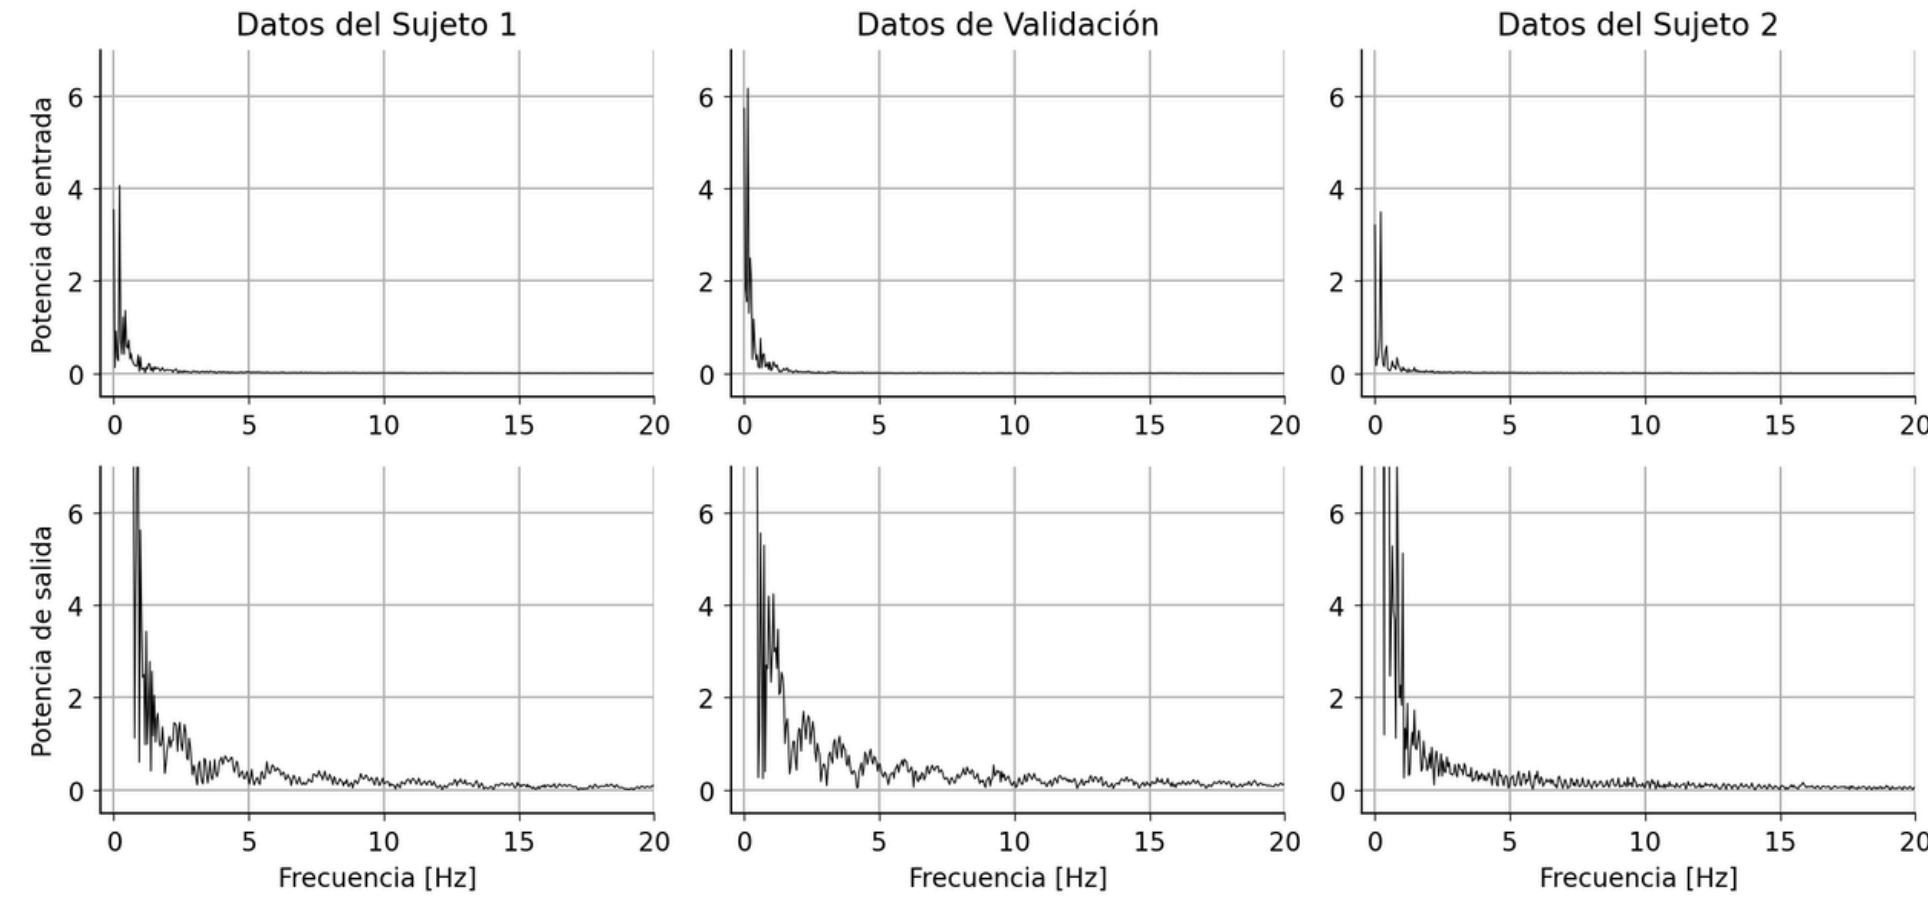


FIGURA 2: ESPECTROS FFT

2. Identificación del sistema

Con las señales filtradas del sujeto sano, se evaluaron cuatro estructuras de modelado paramétrico clásico: Box-Jenkins (BJ), ARMAX, ARX y Output Error (OE). Los órdenes seleccionados fueron:

- BJ: $nb=1, nf=1, nc=1, nd=1, nk=1$
- ARMAX: $na=2, nb=2, nc=1, nk=1$

- ARX: $na=3, nb=1, nk=1$
- OE: $nb=1, nf=3, nk=1$

Los modelos se estimaron y simularon centrándose en la parte determinista debido a la dificultad de caracterizar el ruido.

3. Comparación de modelos

El desempeño de cada modelo se cuantificó utilizando la raíz del error cuadrático medio (**RMSE**) y el índice de ajuste (**fit score**), tanto para el conjunto de entrenamiento como para el de validación. También se realizaron comparaciones visuales de las señales reales y las predichas. *El modelo OE demostró ser el más eficaz.*

4. Sensibilidad y optimización

Se llevó a cabo un análisis de sensibilidad paramétrica en el modelo OE para *identificar los coeficientes más influyentes (b_2, b_3, a_3, a_4)*. Estos parámetros clave se optimizaron utilizando el algoritmo Nelder-Meads para adaptar el modelo al sujeto patológico, *minimizando el error cuadrático acumulado* entre la salida simulada y la señal real.

5. Análisis Temporal y Frecuencial

Se realizó un análisis dinámico de los modelos obtenidos para ambos sujetos. Esto incluyó el cálculo de la respuesta al impulso en el dominio temporal y la generación de diagramas de Bode en el dominio de la frecuencia, permitiendo una interpretación fisiológica de las diferencias entre los sistemas.

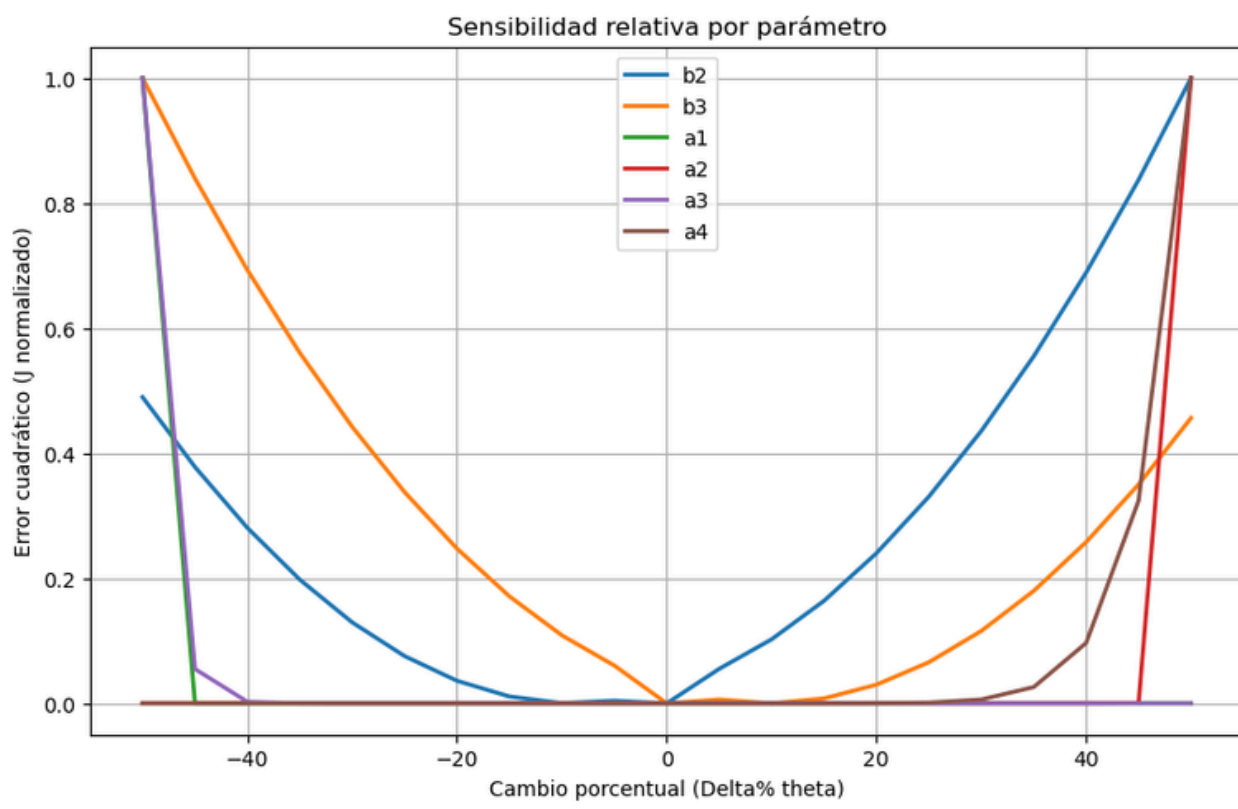


FIGURA 5: SENSIBILIDAD PARAMÉTRICA

4 RESULTADOS

Modelo	RMSE (Identificación)	FIT (Identificación)	RMSE (Validación)	FIT (Validación)
OE	66.66	55.26%	114.83	49.76%
ARX	1.78×10^9	$-1.21 \times 10^9 \%$	6.45×10^8	$-3.51 \times 10^8 \%$
ARMA X	9620.23	-6441.56%	6358.89	-2962.91%
BJ	7281.50	-4964.78%	7284.81	-3462.86%

FIGURA 3: MÉTRICAS DE LOS MODELOS




FIGURA 4: MODELO OPTIMIZADO

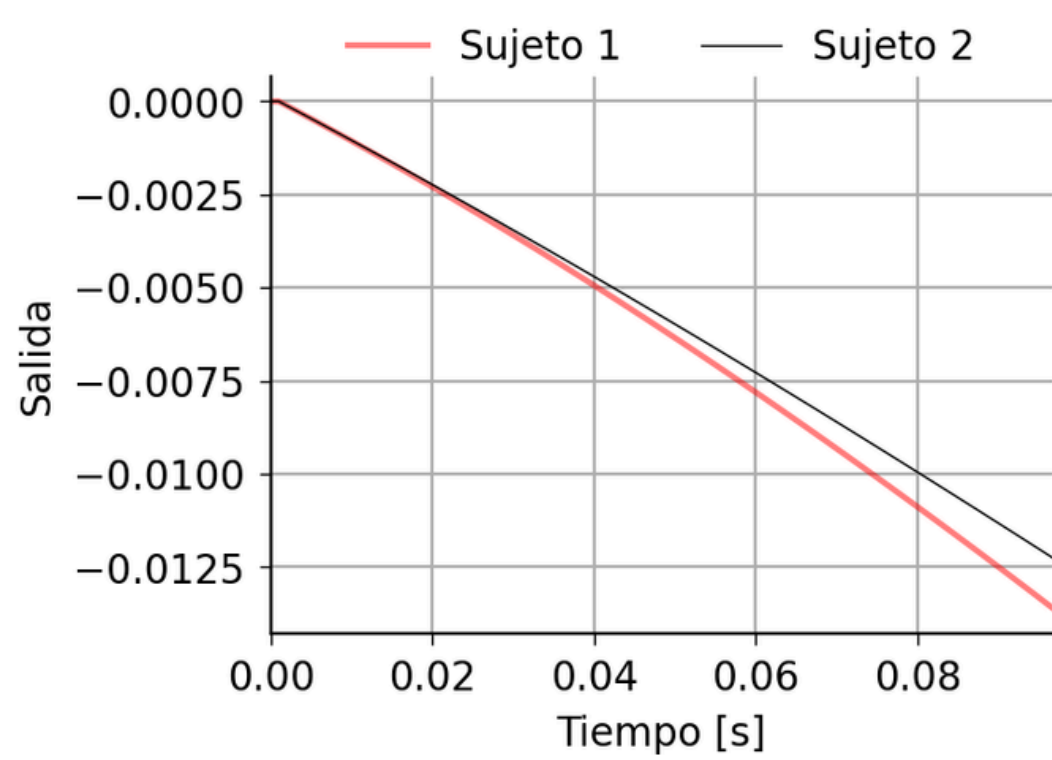


FIGURA 6: RESPUESTA AL IMPULSO

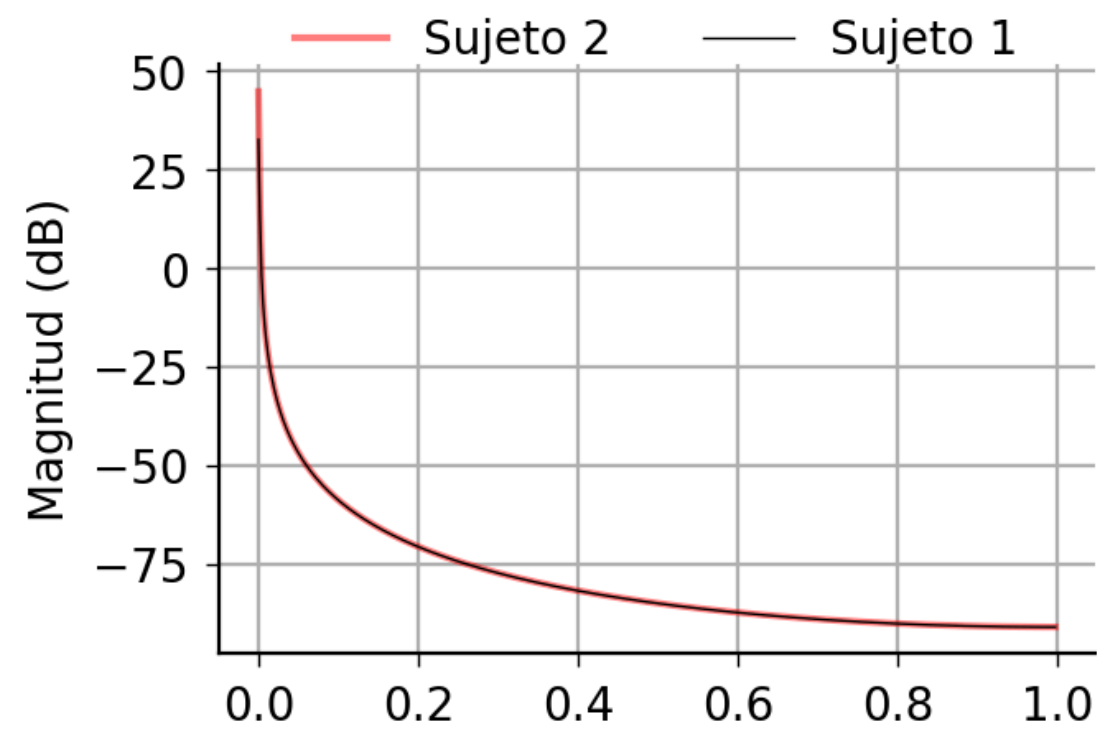


FIGURA 7: DIAGRAMA DE BODE

5 ANÁLISIS

La visualización de las señales de flujo y volumen evidenció ruido y desfases, lo que motivó un preprocesamiento mediante un filtro FIR de fase lineal que preservó la forma de las señales y mejoró su fidelidad. Entre las estructuras evaluadas, el modelo Output Error (OE) fue el más preciso, destacando por su buen ajuste sin necesidad de modelar el ruido, lo que lo hace ideal para señales respiratorias preprocesadas. Su estructura capturó adecuadamente la dinámica temporal del sistema.

El análisis de sensibilidad identificó los parámetros clave (b_2, b_3, a_3, a_4), permitiendo simplificar el modelo y centrar la optimización. Esta optimización adaptó exitosamente el modelo al sujeto patológico, demostrando su flexibilidad frente a distintas condiciones fisiológicas.

Finalmente, el análisis temporal y frecuencial evidenció diferencias claras entre ambos sujetos: el sano mostró una respuesta más rápida y estable, mientras que el patológico presentó una respuesta más prolongada y sensible a frecuencias altas, reflejando diferencias en su mecánica respiratoria.

6 CONCLUSIONES

El estudio confirmó la eficacia del modelado dinámico del sistema respiratorio mediante técnicas de identificación de sistemas aplicadas a señales de flujo y volumen. El filtrado FIR fue clave para eliminar ruido no fisiológico y permitió adoptar un enfoque determinista en el modelado.

El modelo Output Error (OE) fue el más preciso, superando a estructuras más complejas, lo que valida el uso de modelos deterministas con datos preprocesados. El análisis de sensibilidad facilitó la simplificación del modelo al identificar parámetros clave, que luego fueron optimizados con éxito para representar al sujeto patológico.

Los análisis temporal y frecuencial demostraron que las diferencias fisiológicas observadas están asociadas a variaciones mecánicas respiratorias. En conjunto, los resultados respaldan el uso de modelos deterministas filtrados como herramienta útil en análisis clínico y simulaciones fisiológicas personalizadas.

REFERENCIAS

[1] A. R. Carvalho y W. A. Zin, "Respiratory system dynamical mechanical properties: modeling in time and frequency domain," Biophysical Reviews, vol. 3, no. 1, pp. 71–84, 2011. DOI: 10.1007/s12551-011-0048-5. [2] J. H. T. Bates y G. B. Allen, "The Estimation of Lung Mechanics Parameters in the Presence of Pathology: A Theoretical Analysis," Annals of Biomedical Engineering, vol. 34, no. 3, pp. 384–392, Mar. 2006. DOI: 10.1007/s10439-005-9056-6. [3] N. Akshaykumar y D. Subbulekshmi, "Process Identification with Autoregressive Linear Regression Method using Experimental Data: Review," Indian Journal of Science and Technology, vol. 9, no. 39, Oct. 2016, doi: 10.17485/ijst/2016/v9i39/91470. [4] H. M. Tun, "Photoplethysmography (PPG) Scheming System Based on Finite Impulse Response (FIR) Filter Design in Biomedical Applications," International Journal of Electrical and Electronic Engineering & Telecommunications, vol. 10, no. 4, pp. 272–282, Jul. 2021, doi: 10.18178/ijeetc.10.4.272-282. [5] McGee S. Respiratory rate and abnormal breathing patterns. In: McGee S, ed. Evidence-Based Physical Diagnosis. 5th ed. Philadelphia, PA: Elsevier; 2022:chap 19. [6] T. Chai and R. R. Draxler, "Root mean square error (RMSE) or mean absolute error (MAE)?," Geosci. Model Dev. Discuss., vol. 7, pp. 1525–1534, 2014, doi: 10.5194/gmdd-7-1525-2014. [7] T. Russi, A. Packard, R. Feeley, and M. Frenklach, "Sensitivity Analysis of Uncertainty in Model Prediction," J. Phys. Chem. A, vol. 112, no. 12, pp. 2579–2588, 2008, doi: 10.1021/jp076861c. [8] S. A. Billings and K. L. Lee, "Nonlinear Fisher discriminant analysis using a minimum squared error cost function and the orthogonal least squares algorithm," Neural Networks, vol. 15, no. 2, pp. 263–270, Mar. 2002, doi: 10.1016/S0893-6080(02)00014-2. [9] M. A. Luersen y R. Le Riche, "Globalized Nelder–Mead method for engineering optimization," Computers and Structures, vol. 82, no. 23–24, pp. 2251–2260, 2004, doi: 10.1016/j.compstruc.2004.03.072.